MACHINE LEARNING I · UNIVERSIDAD EAN · PROYECTO FINAL INTEGRADOR

Priorización de contratos públicos con riesgo de sobrecosto en SECOP II

Propuesta de intraemprendimiento para las oficinas de control interno: un modelo que estima, al adjudicar un contrato, la probabilidad de que termine costando más de lo adjudicado, para que un equipo con capacidad limitada revise primero los contratos más riesgosos.

64,8 %
de acierto al revisar el 10 % de contratos más riesgosos (25,5 % al azar)

65 %
del monto adicionado en 2024 estaba en ese 10 %

0,551
PR-AUC en la prueba 2024, frente a 0,255 al azar

31.486
contratos vigentes 2025-2026 ordenados por riesgo

Recomendación. Que la oficina de control interno adopte el ranking como un nuevo proceso de priorización: revisar primero los contratos vigentes de mayor probabilidad, hasta donde alcance la capacidad (con el 10 % de los vigentes son 3.149 contratos). Complementarlo con la revisión de los contratos más grandes, que concentran el monto, y con una pequeña muestra al azar para vigilar el desempeño y los sesgos. Es una herramienta para priorizar, no para sancionar.

Equipo SECOPE	Sebastián Gómez (jefe) · Kimberly Moreno (líder) · Luly Castiblanco (crack)
Enfoque	Intraemprendimiento (anexo A: `anexo_A_enfoque.md`)
Repositorio	https://github.com/kimmoreno03/ml1-trabajo-final
Despliegue	https://kimmoreno03.github.io/ml1-trabajo-final/
Datos	SECOP II, Portal Nacional de Datos Abiertos (datos.gov.co), descarga del 20 de octubre de 2026
Fecha	Octubre de 2026

1. Problema, decisión y propuesta de intraemprendimiento

En la contratación pública colombiana con competencia, **uno de cada cuatro contratos termina costando más de lo adjudicado**. Entre 2021 y 2024, en los 244.518 contratos terminados que analizamos, las adiciones de valor sumaron **19,7 billones de pesos**, entre el 16 % y el 20 % de lo adjudicado cada año. Un contrato con sobrecosto crece, en la mediana, un 39 % sobre su valor adjudicado.

Las adiciones son legales hasta cierto límite (artículo 40 de la Ley 80 de 1993), pero cada una es dinero que no estaba en el presupuesto del proceso y suele reflejar una mala estimación o un cambio de alcance. Hoy, las oficinas de control interno eligen qué contratos revisar con reglas intuitivas, como empezar por los más grandes, y no alcanzan a revisarlos todos.

Pregunta	Respuesta en este proyecto
¿Qué decisión se apoya?	Qué contratos vigentes revisar primero, cuando la capacidad no alcanza para revisarlos todos.
¿Quién la toma?	El jefe de la oficina de control interno de una entidad que contrata por SECOP II (usuario principal). También sirve a una contraloría o a una veeduría ciudadana.
¿A quién afecta?	A las entidades y contratistas cuyos contratos se revisan primero, y a la ciudadanía, que financia las adiciones.
¿Cómo se mide el éxito?	Con la capacidad de revisar el 10 % de los contratos: el **acierto** en lo revisado (precisión), la fracción de **sobrecostos encontrados** y el **monto adicionado cubierto**. La meta es superar a la regla intuitiva de revisar primero los contratos más grandes.

1.1 Propuesta de intraemprendimiento

El proyecto transforma un **proceso interno**: la forma en que una oficina de control interno elige qué contratos auditar. No es un producto para vender, sino una mejora del proceso de seguimiento a la contratación dentro de la propia entidad. El detalle y las evidencias están en el anexo A.

Elemento	Contenido
Organización y usuario	Oficina de control interno de una entidad pública que contrata por SECOP II con modalidades competitivas. Usuario: el jefe de la oficina y su equipo de auditores.
Propuesta de valor	Una lista ordenada, actualizable cada año y sin costo de licencia, que dice qué contratos vigentes revisar primero. Se usa desde una página web, con filtros y descarga en CSV.
Hipótesis de mejora	Con la misma capacidad de revisión, priorizar con el modelo encuentra más contratos que terminan con sobrecosto que la regla actual de revisar primero los más grandes.
Impacto estimado	En 2024, revisando el 10 % de los contratos (6.802), el modelo habría encontrado **4.411 sobrecostos**, frente a 3.060 con la regla de los más grandes (**+1.351, un 44 % más**) y unos 1.730 al azar. Ese 10 % concentraba cerca de **3,0 billones** de los 4,6 billones adicionados en 2024.
Supuestos	La capacidad de revisión es del 10 % de los contratos; los contratos futuros se comportan como los de 2024; el impacto se mide como sobrecostos y monto *bajo revisión*, no como dinero ahorrado, porque revisar un contrato no garantiza evitar la adición.
Ruta de validación	Un piloto de un año con una oficina de control interno, que compara el ranking con su regla actual sobre los mismos contratos (sección 6.4).

1.2 Planteamiento como problema de aprendizaje

Es una **clasificación binaria supervisada**. La unidad es un contrato de SECOP II que corresponde a un proceso con un solo contrato, y la predicción se hace en el momento de adjudicar, con información conocida entonces. La etiqueta es:

> sobrecosto = 1 si valor final del contrato > valor total adjudicado × 1,001

En SECOP II, el valor del contrato se actualiza con cada adición, así que muestra el valor final. El margen de 0,1 % evita marcar diferencias de redondeo.

Por qué este paradigma. Es supervisado porque la etiqueta se observa en los contratos ya terminados. Es clasificación y no regresión porque la decisión es binaria (revisar o no) y lo que se necesita es un orden por riesgo; el monto de la adición está muy concentrado (el 1 % de los contratos con sobrecosto suma el 43 % de las adiciones) y una regresión sobre él quedaría dominada por pocos casos. El resultado es **prescriptivo**: el modelo final ordena por riesgo los contratos vigentes de 2025-2026 que todavía no tienen adiciones.

Pérdida técnica y métrica de negocio. Los modelos se entrenan minimizando la entropía cruzada (pérdida logarítmica), que es la función de pérdida. El éxito para el negocio se mide aparte, con la precisión en el 10 % revisado y el monto adicionado cubierto; para elegir el modelo se usa la PR-AUC, que resume la calidad del orden.

Riesgos éticos iniciales. Que una probabilidad alta se lea como sospecha de corrupción; que el modelo concentre las revisiones en ciertos departamentos, sectores o modalidades; y que deje fuera, sin decirlo, a la contratación directa. La sección 6 los trata con sus controles.



Figura 1. Crecimiento del valor en los contratos con sobrecosto (2021-2024, antes de descartar los que superan el tope legal). El 28,6 % crece justo hasta el límite de 50 % de la Ley 80; por encima, solo es legal llegar al tope en salarios mínimos de cada contrato (líneas grises), y lo que lo supera se trata como error de registro.

2. Datos

2.1 De dónde vienen

Usamos tres conjuntos abiertos de SECOP II, publicados por la Agencia Nacional de Contratación Pública - Colombia Compra Eficiente en datos.gov.co con licencia CC BY-SA 4.0, y descargados el 20 de octubre de 2026 por la API del portal. El detalle de columnas, tipos y faltantes está en la ficha de datos.

Conjunto	ID	Qué aporta	Filas descargadas
Contratos Electrónicos	jbjy-vk9h	entidad, tipo y modalidad, cláusulas, tipo de proveedor y valor final	442.367*
Procesos de Contratación	p6dx-8zbt	precio base, valor adjudicado, duración pactada y competencia	741.747
Adiciones	cb9c-h8sn	tipo y fecha de cada modificación (sin montos)	consultas por llave

* Contratos firmados entre 2021 y octubre de 2026. Los de 2021-2024 (284.715) forman la base del modelo; los de 2025-2026 se usan solo para el ranking de contratos vigentes.

Los contratos se cruzan con su proceso (`proceso_de_compra` = `id_del_portafolio`), tomando la última publicación de cada proceso.

2.2 Qué calidad tienen

Paso (contratos firmados 2021-2024)	Contratos	Qué problema resuelve
Descargados (modalidades con valor adjudicado)	284.715	—
Un contrato por proceso, cruzan con su proceso, valores positivos	251.794	con varios lotes, el valor adjudicado total no se puede repartir
Valor adjudicado entre 0,1 y 1,5 veces el precio base	250.344	errores de digitación: había compras de 114 millones «adjudicadas» por 12.858 billones
Terminados (fecha de fin hace al menos 30 días)	248.173	la etiqueta de un contrato en ejecución todavía puede cambiar
Dentro del tope legal de adiciones (base del modelo)	**244.518**	**crecimientos imposibles por ley: errores de registro**

- **Errores de digitación:** 2.032 registros (0,52 %) tenían un valor adjudicado incoherente con el precio base. Con ellos, lo adjudicado sumaba 115.856 billones de pesos; sin ellos, 250,5 billones. Los filtros siguientes retiran otros registros con montos atípicos: en la base final, lo adjudicado suma 112,5 billones y las adiciones son el 17,5 % de esa cifra.
- **Tope legal:** se calcula en salarios mínimos (1 + 0,5 × SMMLV del año de la última adición / SMMLV del año de firma). Salen 3.655 contratos. Un corte fijo de 1,5 veces en pesos sacaría 5.600 y descartaría 1.945 contratos legales; se usa como prueba de robustez.
- **Validación de la etiqueta:** en una muestra de 300 contratos con sobrecosto y 300 sin él, el 99,7 % de los primeros tiene una modificación de valor o general registrada, frente al 32,3 % de los segundos.
- **Faltantes:** solo 3 duraciones sin unidad (se imputan). La categoría UNSPSC sin código (`UNSPECIFIED`) sube de 0,7 % en 2021 a 10,1 % en 2024 por un cambio de registro; se trata como categoría propia.

2.3 A quién representan y a quién no

Representan

- La contratación con competencia y valor adjudicado: licitación, selección abreviada, mínima cuantía, concurso de méritos, y régimen especial o directa con ofertas. Es el **9,5 %** de los contratos del período.

No representan

- La **contratación directa** (77,9 % de los contratos) y el **régimen especial sin ofertas** (12,6 %): sin competencia no hay valor adjudicado, así que no se puede medir su sobrecosto. Además, sus adiciones son sobre

- Procesos con un solo contrato, ya terminados, de todo el país y de todos los sectores.

todo prórrogas de servicios personales, otro fenómeno.

- Procesos con varios lotes y contratos que siguen en ejecución.

3. Preparación y diseño experimental

3.1 Variables

El modelo usa **30 variables conocidas al adjudicar**: 20 categóricas (departamento, orden, sector y rama de la entidad; tipo y modalidad del contrato; origen y destino de los recursos; tipo de proveedor; seis cláusulas; segmento y familia UNSPSC del bien o servicio) y 10 numéricas (precio base y valor adjudicado en logaritmo, descuento al adjudicar, duración pactada en días, cinco indicadores de competencia y mes de firma). Ninguna identifica a la entidad o al proveedor. La lista completa está en el anexo 1.

3.2 Cómo se evitó la fuga de información

Muchas columnas de SECOP II se actualizan durante la ejecución. Una variable entra solo si se conoce al adjudicar y no cambia después. Se excluyen el valor final, el estado, las fechas y la duración real del contrato, los días adicionados, los pagos y las fuentes de financiación. También se excluyen la cláusula de liquidación, porque su distribución cambia después de firmar (distancia de variación total de 0,125, sobre el umbral de 0,10), y el texto libre del objeto, porque repite la categoría UNSPSC e identifica a la entidad.

Se verificó que la duración del proceso es la pactada y no se actualiza con las prórrogas: coincide con la duración final en el 44 % de los contratos sin sobrecosto y solo en el 20 % de los que tienen sobrecosto. El anexo 2 muestra el efecto de la fuga: con esas columnas, la PR-AUC subiría de 0,55 a 0,84, y con el valor final a 0,99.

3.3 Cómo se trató el desbalance

La clase positiva es el 25,5 %. No se remuestrea: se elige una métrica adecuada y se ajustan los modelos que lo necesitan.

- **Métrica principal: PR-AUC.** Mide la precisión de la lista ordenada que revisa el equipo y se compara con 0,255 al azar. La ROC-AUC se apoya en la tasa de falsos positivos, cuyo denominador son los muchos contratos sanos, y se ve optimista cuando la clase positiva es minoritaria (Saito y Rehmsmeier, 2015; Davis y Goadrich, 2006). Se reporta como complemento.
- **Pesos por clase** en la regresión logística. Mejora el ordenamiento, pero infla sus probabilidades, como muestra la calibración (sección 5).

3.4 Cómo se protegió el conjunto de prueba

Conjunto	Años de firma	Contratos	Entidades	Uso
Entrenamiento	2021-2023	176.495	2.542	ajustar los modelos y tomar todas las decisiones
Prueba	2024	68.023	2.318	confirmar, una sola vez

- **Partición temporal:** simula construir el modelo a comienzos de 2024 y usarlo ese año. Una partición aleatoria mezclaría años y daría una evaluación optimista.
- **Validación cruzada agrupada por entidad** (`GroupKFold`, 5 pliegues de unas 500 entidades y 35.299 contratos). Una entidad nunca queda a la vez en entrenamiento y validación, para que el modelo no «reconozca» a la entidad. Con ella se eligen los hiperparámetros, las iteraciones del boosting, las épocas de la red, el umbral y el campeón.

- **Agrupada en lugar de estratificada:** con 2.542 entidades, agrupar es lo que evita la fuga entre pliegues, y la proporción de positivos queda equilibrada sin forzarla: entre 24,3 % y 26,9 % en los cinco pliegues, frente a 25,5 % en total.
- **Preprocesamiento dentro de cada pliegue:** one-hot (categorías con menos de 30 casos agrupadas), imputación por la mediana y estandarización $z = (x - \mu)/\sigma$ para la logística y la red, ajustados solo con los datos de entrenamiento de cada pliegue dentro de un `Pipeline`. Los árboles reciben un código ordinal sin escalar; el Gradient Boosting usa categorías nativas.
- **Parada temprana interna desactivada:** separaría la validación por filas y mezclaría entidades.

4. Modelado

4.1 Línea base y modelos comparados

La línea base asigna a todos los contratos la tasa promedio (25,5 %): es lo que se logra sin modelo. Se compararon cinco modelos de complejidad creciente.

Modelo	Búsqueda en validación cruzada	Configuración elegida
Regresión logística	regularización $C \in \{0{,}01; 0{,}1; 1\}$, pesos por clase	$C = 0{,}1$
Árbol de decisión	poda por complejidad con la regla de 1 error estándar; hojas ≥ 50	86 hojas, profundidad 11
Bosque aleatorio	variables por corte {raíz, 30 %} × hoja mínima {5, 20}	raíz, hoja 5; 400 árboles
Gradient Boosting (histogramas)	hojas {15, 31}; hasta 600 iteraciones, evaluadas cada 10	31 hojas, 200 iteraciones, tasa 0,06
Red neuronal (MLP)	capas (32) o (64, 32); regularización {0,0001; 0,01}; hasta 30 épocas	(64, 32), 0,01, 3 épocas; 32.321 parámetros

4.2 Cómo se eligió el modelo final

La regla se fijó antes de mirar la prueba:

1. Se toma el modelo con mejor PR-AUC en validación cruzada.
2. Son elegibles los modelos a menos de un **error estándar pareado** del mejor: la diferencia se calcula pliegue por pliegue, lo que elimina la variación debida a qué entidades cayeron en cada pliegue.
3. Entre los elegibles se elige el más interpretable (logística, árbol, bosque, boosting, red).
4. La prueba solo confirma.

Modelo	PR-AUC validación	Diferencia con el mejor	Error estándar pareado	¿Elegible?
Gradient Boosting	**0,551**	**—**	**—**	**sí (el mejor)**
Bosque aleatorio	0,537	−0,014	0,003	no
Red neuronal	0,536	−0,015	0,002	no
Regresión logística	0,504	−0,046	0,001	no
Árbol de decisión	0,475	−0,075	0,004	no

El bosque y la red quedan más de cuatro errores estándar por debajo, así que solo el **Gradient Boosting** es elegible y es el campeón. Los modelos de conjunto superan con claridad a la logística y al árbol porque el

riesgo depende de combinaciones de variables (por ejemplo, el tipo de bien con el plazo) que un modelo lineal no capta.

Modelo final. Confirmado en la prueba, el campeón se reentrena con los 244.518 contratos de 2021-2024 y calcula la probabilidad de los contratos vigentes.

5. Evaluación

5.1 Desempeño en la prueba (contratos de 2024)

Modelo	PR-AUC	ROC-AUC	Precisión en el 10 %	Brier	Umbral F1	Precisión / exhaustividad con F1
Línea base	0,255	0,500	26,1 %	0,190	—	—
Regresión logística	0,490	0,745	58,6 %	0,206	0,477	40,7 % / 71,8 %
Árbol de decisión	0,469	0,726	57,1 %	0,166	0,261	42,4 % / 61,7 %
Bosque aleatorio	0,548	0,779	65,6 %	0,153	0,273	45,9 % / 69,1 %
Gradient Boosting	**0,551**	**0,783**	**64,8 %**	**0,152**	**0,263**	**46,1 % / 69,9 %**
Red neuronal	0,533	0,769	64,1 %	0,157	0,234	40,6 % / 78,7 %

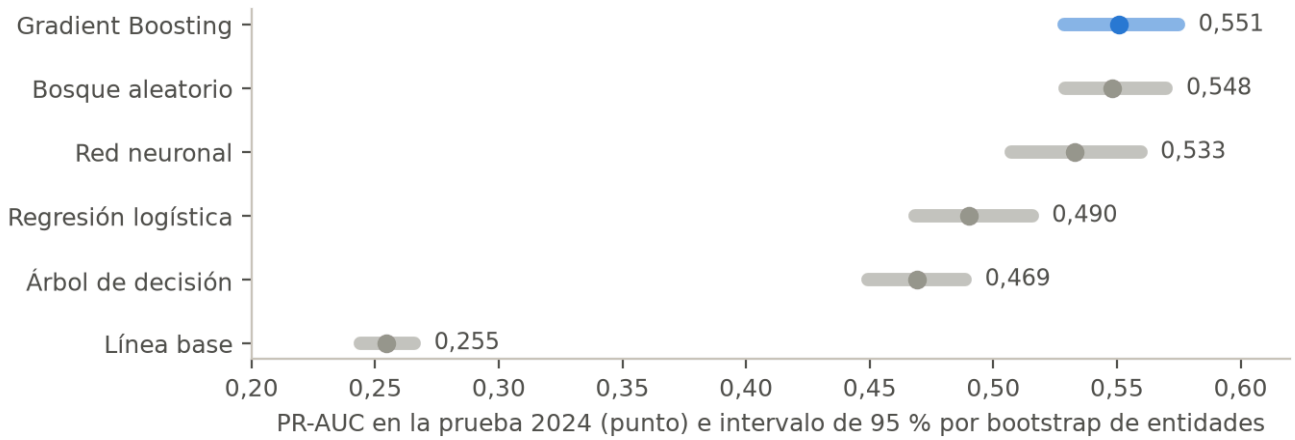


Figura 2. PR-AUC en la prueba con intervalos de 95 % obtenidos remuestreando entidades 500 veces. El campeón logra 0,551 [0,529; 0,575]. El bosque aleatorio no se distingue de él en la prueba (diferencia −0,003 [−0,013; +0,012]), pero la regla se aplica en validación: la prueba confirma, no reabre la elección.

5.2 Qué métricas importan por el costo del error

Error	Qué significa	Costo	Con el 10 % en 2024
Falso positivo	revisar un contrato que no termina con sobrecosto	horas del equipo de control y una carga para la entidad y el contratista	2.391 de 6.802 revisiones
Falso negativo	no revisar un contrato que sí termina con sobrecosto	dinero público: un 39 % adicional en la mediana	12.901 sin revisar

Como la capacidad de revisión es la restricción, lo que más pesa es acertar en lo que se revisa: por eso se priorizan la **precisión en el 10 %** y la **PR-AUC**. El puntaje de Brier mide además si las probabilidades son correctas: el campeón logra 0,152, frente a 0,190 al asignar la tasa promedio.

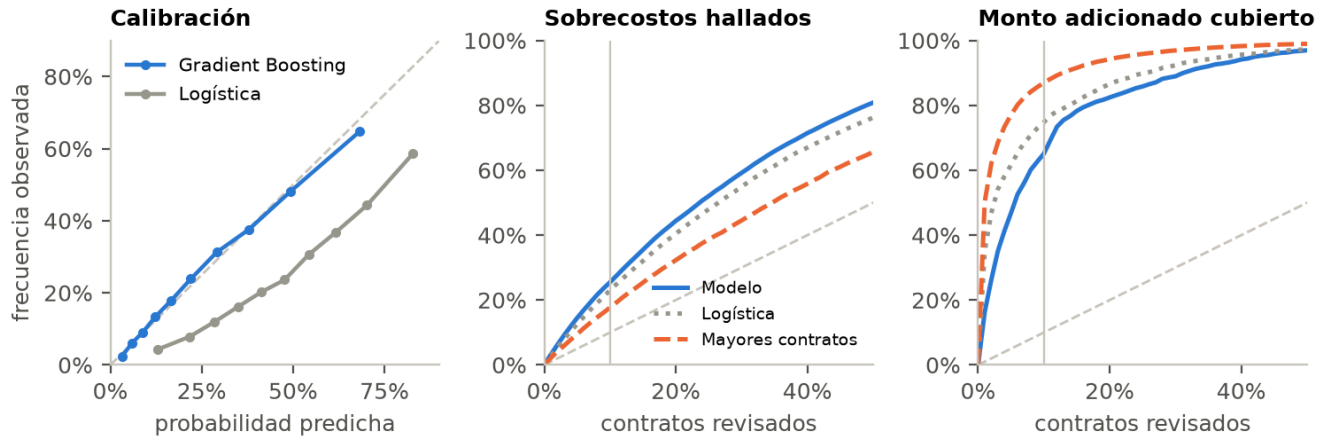


Figura 3. Izquierda: calibración en 2024 (10 grupos del mismo tamaño). Las probabilidades del campeón coinciden con lo observado (en el grupo más riesgoso promete 68 % y ocurre 65 %); las de la logística están infladas por los pesos por clase. Centro y derecha: qué fracción de los sobrecostos y del monto adicionado se encuentra según cuántos contratos se revisan (línea vertical: 10 %).

5.3 Valor de priorizar

Revisando (contratos)	Criterio	Hallados	Precisión	% de los casos	% del monto
1 % (680)	modelo	553	81,3 %	3,2 %	16,2 %
1 % (680)	contratos más grandes	372	54,7 %	2,1 %	50,2 %
10 % (6.802)	**modelo**	**4.411**	**64,8 %**	**25,5 %**	**65,1 %**
10 % (6.802)	contratos más grandes	3.060	45,0 %	17,7 %	87,0 %
20 % (13.605)	modelo	7.690	56,5 %	44,4 %	82,4 %
20 % (13.605)	contratos más grandes	5.592	41,1 %	32,3 %	94,2 %

Revisando el 10 % que señala el modelo, 65 de cada 100 contratos tienen sobrecosto: 2,5 veces lo que da revisar al azar. Se encuentran más casos y se acierta más que revisando los contratos más grandes. Revisar los más grandes cubre más monto (87 %), porque las adiciones grandes ocurren en contratos grandes y el modelo estima si ocurre un sobrecosto, no su tamaño. Los dos criterios se complementan, y por eso la propuesta los combina.

5.4 Estabilidad, sesgo y varianza

- **Entre pliegues:** la PR-AUC del campeón varía con una desviación de 0,033 entre los 5 pliegues por entidad.
- **Otra ventana temporal** (2021-2022 → 2023): PR-AUC 0,568 (logística 0,518).
- **Otra definición del objetivo** (corte nominal de 1,5 veces): PR-AUC 0,544. Las 5 variables principales coinciden en todos los escenarios.
- **Dentro de cada modalidad:** ROC-AUC entre 0,73 y 0,80 en siete de ocho modalidades (0,643 en licitación de obra, con solo 573 contratos). El modelo no se limita a distinguir modalidades.
- **Curva de aprendizaje:** 0,516 con 25 % de los datos, 0,532 con 50 %, 0,541 con 75 % y 0,551 con 100 %.

- **Diagnóstico de sesgo y varianza:** la PR-AUC de validación (0,551) y la de prueba (0,551) coinciden, y la desviación entre pliegues es pequeña, así que el modelo no está sobreajustado (varianza controlada). La curva de aprendizaje crece cada vez menos: duplicar los datos ya aportaría poco. El límite que queda es de sesgo, es decir, de información: para mejorar hacen falta variables nuevas, como el historial de la entidad y del proveedor, más que más contratos o modelos más complejos.

5.5 Qué impulsa el riesgo

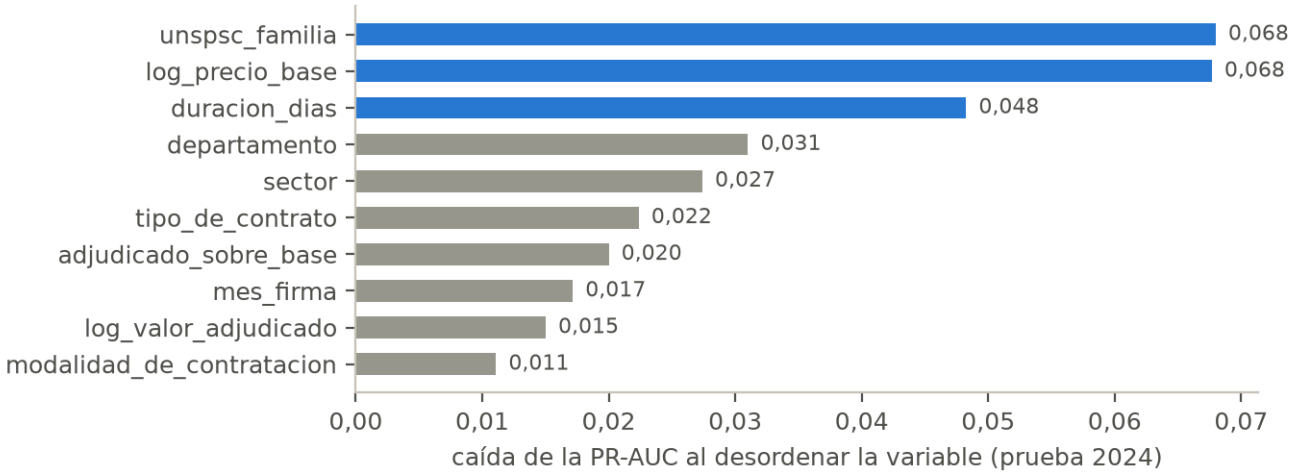


Figura 4. Importancia por permutación en la prueba: cuánto cae la PR-AUC al desordenar cada variable.

Lo que más pesa es **qué se compra** (familia UNSPSC), **el tamaño del presupuesto** y **el plazo pactado**. La dependencia parcial muestra la dirección: la probabilidad media pasa de 13,6 % con un precio base de 5 millones a 36,7 % con 1.280 millones, y de 19,8 % con 30 días de plazo a cerca de 36 % con 240-300 días. Los servicios de demanda variable (mantenimiento de vehículos 34,1 %, transporte de pasajeros 32,1 %, alimentación 30,6 %, seguros 29,8 %) son los más propensos; las consultorías de alcance definido, los menos (14,9 %). Son asociaciones aprendidas por el modelo, no causas.

5.6 Umbral recomendado

- **Operar por capacidad (recomendado):** revisar en orden los N contratos de mayor probabilidad que permita el equipo. En 2024, el 10 % de mayor riesgo correspondía a probabilidades desde 0,57; en los vigentes 2025-2026, el 10 % son 3.149 contratos con probabilidad desde 0,62 (los vigentes son más recientes y más largos, así que su probabilidad se lee como orden de prioridad).
- **Umbral fijo alternativo: 0,263**, el que maximiza F1 en las predicciones fuera de pliegue. Marca el 38,6 % de los contratos, con 46 % de precisión y 70 % de exhaustividad; solo sirve si la capacidad alcanza para revisar tantos.

6. Decisión, límites y gobernanza

6.1 Qué se recomienda

1. Que la oficina de control interno use el ranking de la página para decidir qué contratos vigentes revisar primero, empezando por los de prioridad muy alta (1 %) y alta (10 %).
2. Complementarlo con la revisión de los contratos más grandes, que concentran el monto adicionado.
3. Revisar también una pequeña muestra al azar, para medir el desempeño real sin el sesgo de solo revisar lo que el modelo señala.
4. Comparar el ranking con lo que ocurra cuando esos contratos terminen, y reentrenar cada año.

6.2 Bajo qué condiciones deja de valer

- **Fuera de su alcance:** no aplica a la contratación directa ni al régimen especial sin ofertas, ni a procesos con varios lotes. No figurar en la lista no significa no tener riesgo.
- **Cambios en la norma** (otro tope de adiciones, otras modalidades) o **en el registro de SECOP II**, como el aumento de la categoría UNSPSC sin código desde 2023.
- **Deriva:** si el acierto del 10 % más riesgoso, medido al terminar los contratos priorizados, baja de 45 % (lo que logra revisar los contratos más grandes), hay que reentrenar antes de seguir usándolo.
- **Contratos vigentes:** son más recientes y más largos que los de entrenamiento, y su registro puede tener rezagos; por eso el ranking se lee como orden y no como probabilidad exacta.

6.3 A quién podría perjudicar

- **Entidades y contratistas de los grupos que el modelo marca más.** En la prioridad alta, la licitación de obra pública pesa 5,3 veces lo que pesa entre todos los vigentes; los contratos de seguros, 3,1 veces; el sector transporte, 1,7 veces; Cundinamarca, 1,6 veces. Recibirían más revisiones, y hay que vigilar que la diferencia se explique por su riesgo observado y no por un sesgo del registro.
- **Entidades cumplidas en grupos de alto riesgo:** el departamento y el sector suben la probabilidad de una entidad por el comportamiento promedio de su grupo.
- **Uso indebido:** una probabilidad alta no prueba ninguna irregularidad. El modelo sirve para priorizar, siempre con revisión humana, y no para sancionar ni para señalar públicamente a una entidad o un contratista.

6.4 Ruta para validar la hipótesis de intraemprendimiento

Los resultados de 2024 son una validación retrospectiva. Para comprobar la hipótesis con usuarios reales, se propone un piloto con una oficina de control interno:

Etapa	Qué se hace	Qué se mide
1. Línea base (mes 1)	Registrar qué contratos vigentes revisaría la oficina con su regla actual y, en paralelo, cuáles señala el ranking, con la misma capacidad.	Coincidencia entre ambas listas.
2. Operación (meses 2 a 6)	La oficina revisa la unión de las dos listas y una muestra al azar del 1 %, sin saber de qué lista viene cada contrato.	Hallazgos por revisión y horas por revisión, según la lista de origen.
3. Cierre (meses 7 a 12)	Esperar a que terminen los contratos revisados y comparar cuáles tuvieron adiciones.	Precisión de cada lista. Se acepta la hipótesis si el ranking supera a la regla actual (en 2024: 64,8 % frente a 45,0 %).
4. Adopción	Entrevistar a los auditores sobre la utilidad y la claridad de la página, y ajustar los filtros.	Satisfacción de los usuarios y decisión de adoptar el proceso.

7. Roles y trabajo en equipo

Integrante y perfil	Aporte
Sebastián Gómez · jefe	Planteamiento del problema y de la decisión, diseño metodológico (validación, métricas y regla del campeón), cuaderno de modelado y página de resultados.
Kimberly Moreno · líder	Coordinación del equipo, repositorio oficial de la entrega, revisión de los datos y de la fuga de información, primera versión del cuaderno, integración de cambios por solicitudes de extracción y publicación en GitHub Pages.
Luly Castiblanco · crack	Revisión de los datos y de los resultados, y preparación de la exposición.

El uso de inteligencia artificial se declara en `declaracion_IA.md`.

8. Cómo usé lo aprendido en las microcredenciales

El equipo aplicó tres microcredenciales EanX de la unidad. Cada técnica se usó en una parte concreta del proyecto:

Microcredencial EanX	Técnica o herramienta	Dónde se aplicó en el proyecto
Creatividad y Pensamiento Crítico con Prompting Engineering	Definir el reto, explorar alternativas y cerrar con una propuesta de valor	El reto se redefinió de «predecir sobrecostos» a «decidir qué revisar primero con capacidad limitada», y se cerró con la propuesta de valor del intraemprendimiento para la oficina de control interno (sección 1.1). Se exploraron tres definiciones del objetivo (valor final frente a precio base, frente a lo facturado y frente a lo adjudicado) y se eligió la última con evidencia (sección 1.2). También se descartó una calculadora de parámetros en favor de un ranking prescriptivo.
	Prompting con criterio propio: verificar lo que propone la IA	Las propuestas de la IA sobre columnas con fuga se contrastaron con los datos antes de aceptarlas: por ejemplo, que las fuentes de financiación suman el valor final y que la fecha de fin se mueve con las prórrogas (sección 3.2 y anexo 2). Lo aceptado y lo descartado se registra en `declaracion_IA.md`.
Investigación 1: Proponente en Investigación	Formulación de hipótesis verificables	La hipótesis de mejora («con la misma capacidad, el ranking encuentra más sobrecostos que revisar primero los contratos más grandes») se planteó de forma medible y se contrastó con los datos de 2024 (secciones 1.1 y 5.3).
	Definición y operacionalización de variables; búsqueda bibliográfica	La variable dependiente se operacionalizó con una regla explícita (valor final > adjudicado × 1,001) y las 30 independientes se definieron con su unidad y el momento en que se conocen (sección 3.1 y anexo 1). La elección de la PR-AUC se sustentó en la literatura (Saito y Rehmsmeier, 2015; Davis y Goadrich, 2006).
Investigación 2: Analiza tu investigación	Gestión y depuración de bases de datos	Depuración en cinco pasos documentados, con el número de registros que sale en cada uno: errores de digitación del valor adjudicado, contratos sin etiqueta definitiva y crecimientos que violan el tope legal (sección 2.2).
	Diseño y validación de instrumentos; discusión de resultados	La etiqueta se validó con una fuente independiente, el conjunto de adiciones, en una muestra de 600 contratos (sección 2.2). El piloto de la sección 6.4 define los instrumentos para recoger evidencia con usuarios reales (registro de hallazgos por revisión y entrevistas a los auditores). Los resultados se discuten frente a la regla actual y a la literatura sobre métricas en clases desbalanceadas (sección 5).

Anexo 1. Variables del modelo

Variable	Qué mide	Tipo y unidad
`unspsc_familia` / `unspsc_segmento`	familia (4 dígitos) y segmento (2 dígitos) del bien o servicio	categórica: 395 y 57 niveles
`log_precio_base` / `log_valor_adjudicado`	presupuesto oficial y valor adjudicado	numérica: ln(1 + pesos)
`adjudicado_sobre_base`	descuento al adjudicar	numérica: razón entre 0,1 y 1,5
`duracion_dias`	plazo pactado del proceso	numérica: días (mes = 30, año = 365)
`numero_de_lotes`, `proveedores_invitados`, `proveedores_con_invitacion`, `respuestas_al_procedimiento`, `proveedores_unicos_con`	competencia en el proceso	numérica: conteos
`mes_firma`	mes de firma	numérica: 1 a 12
`departamento`, `orden`, `sector`, `rama`, `entidad_centralizada`	características de la entidad	categórica: 34, 3, 25, 4 y 2 niveles
`tipo_de_contrato`, `modalidad_de_contratacion`	naturaleza del contrato y forma de selección	categórica: 18 y 12 niveles
`origen_de_los_recursos`, `destino_gasto`	fuente y uso de los recursos	categórica: 2 y 3 niveles
`es_pyme`, `es_grupo`, `tipodocproveedor`	tipo de proveedor (no su identidad)	categórica: 2, 2 y 9 niveles
`obligaci_n_ambiental`, `reversion`, `el_contrato_puede_ser_prorrogado`, `habilita_pago_adelantado`, `documentos_tipo`, `espostconflicto`	seis cláusulas del contrato	categórica: Sí / No (2 o 3 niveles)

Anexo 2. Efecto de la fuga de información

Variante (mismo campeón, prueba 2024)	ROC-AUC	PR-AUC	F1
Modelo limpio (el del proyecto)	**0,783**	**0,551**	**0,555**
+ columnas que cambian durante la ejecución	0,929	0,839	0,732
+ valor final del contrato	0,993	0,986	0,938

Señales de fuga: los contratos en estado «Modificado» tienen 57,8 % de sobrecosto; con días adicionados mayores a 0, la tasa es 53,1 % frente a 22,1 %; la duración calculada con las fechas del contrato tiene una mediana de 202 días con sobrecosto y 66 sin él, porque la fecha de fin se mueve con las prórrogas.

Anexo 3. Reproducibilidad

- **Cuaderno:** `cuaderno_PFI.ipynb` (en el repositorio, `notebooks/sobrecosto_secop.ipynb`). Corre de principio a fin desde un núcleo reiniciado, con rutas relativas a la carpeta del proyecto; en un equipo sin datos ni corridas guardados, descarga y entrena solo (varias horas). Con una corrida guardada, carga los resultados en pocos minutos.
- **Semilla:** 42 en todos los modelos, remuestreos y muestras. Los parámetros y las versiones se guardan con cada corrida (`corridas/<fecha_hora>/registro.json`).
- **Versiones de la corrida reportada (2026-10-21_1326):** Python 3.13.5, scikit-learn 1.8.0, pandas 2.3.3, numpy 2.3.5.
- **Nota:** la asignación de entidades a los pliegues depende de cómo numpy ordena grupos de igual tamaño, lo que puede variar entre procesadores. En otro equipo, la PR-AUC de validación del campeón dio 0,549 en vez de 0,551; la prueba, el campeón y el ranking no cambian.

Referencias

Agencia Nacional de Contratación Pública - Colombia Compra Eficiente. (2026a). *SECOP II - Adiciones* [Conjunto de datos]. Portal Nacional de Datos Abiertos. Recuperado el 20 de octubre de 2026, de https://www.datos.gov.co/Gastos-Gubernamentales/SECOP-II-Adiciones/cb9c-h8sn

Agencia Nacional de Contratación Pública - Colombia Compra Eficiente. (2026b). *SECOP II - Contratos Electrónicos* [Conjunto de datos]. Portal Nacional de Datos Abiertos. Recuperado el 20 de octubre de 2026, de https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Contratos-Electr-nicos/jbjy-vk9h

Agencia Nacional de Contratación Pública - Colombia Compra Eficiente. (2026c). *SECOP II - Procesos de Contratación* [Conjunto de datos]. Portal Nacional de Datos Abiertos. Recuperado el 20 de octubre de 2026, de https://www.datos.gov.co/Estad-sticas-Nacionales/SECOP-II-Procesos-de-Contratacion/p6dx-8zbt

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5-32. https://doi.org/10.1023/A:1010933404324

Congreso de la República de Colombia. (1993). *Ley 80 de 1993, por la cual se expide el Estatuto General de Contratación de la Administración Pública*. Diario Oficial No. 41.094.

Congreso de la República de Colombia. (2007). *Ley 1150 de 2007, por medio de la cual se introducen medidas para la eficiencia y la transparencia en la Ley 80 de 1993*. Diario Oficial No. 46.691.

Congreso de la República de Colombia. (2012). *Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales*. Diario Oficial No. 48.587.

Congreso de la República de Colombia. (2014). *Ley 1712 de 2014, por medio de la cual se crea la Ley de Transparencia y del Derecho de Acceso a la Información Pública Nacional*. Diario Oficial No. 49.084.

Davis, J., y Goadrich, M. (2006). The relationship between precision-recall and ROC curves. En *Proceedings of the 23rd International Conference on Machine Learning* (pp. 233-240). ACM. https://doi.org/10.1145/1143844.1143874

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189-1232. https://doi.org/10.1214/aos/1013203451

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., y Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830.

Saito, T., y Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE, 10*(3), e0118432. https://doi.org/10.1371/journal.pone.0118432